PROJET SMART CITY — AIR QUALITY INDEX (AQI) & AIDE À LA DÉCISION PUBLIQUE

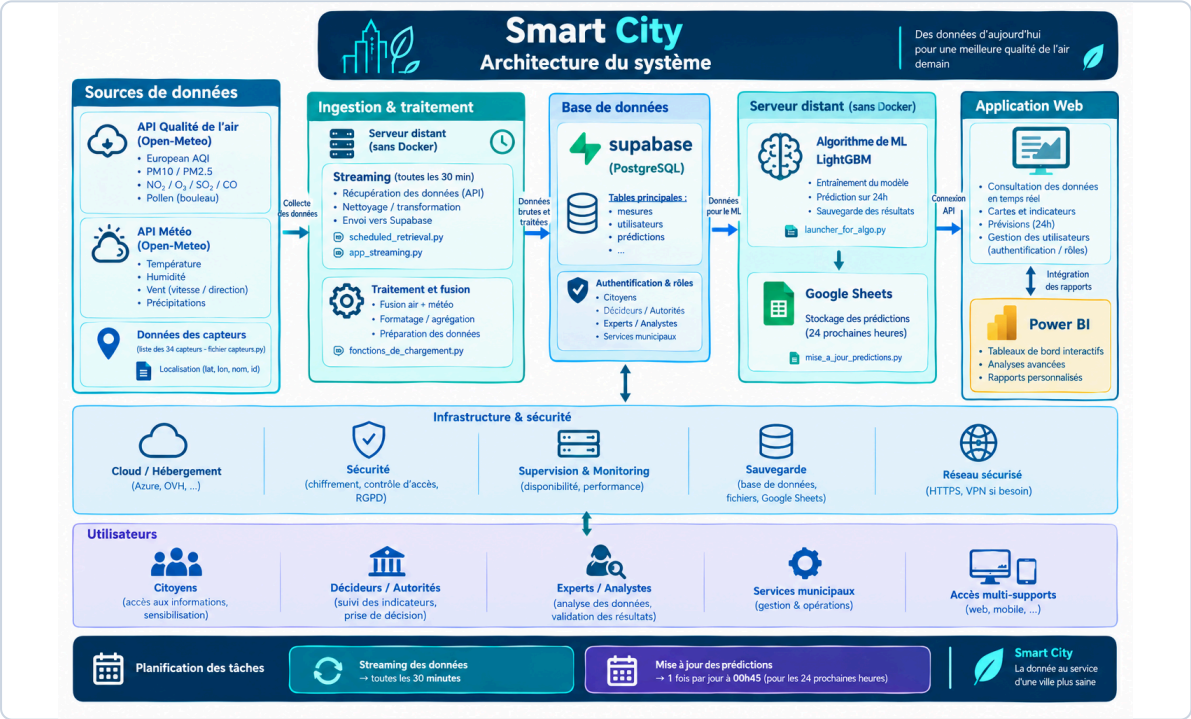
Surveillance Temps Réel, Prévision à 24 Heures, Application Web & Business Intelligence

RAPPORT COMPLET DE PROJET & DOSSIER DES LIVRABLES

Étude, Surveillance et Prédiction à 24 Heures de la Qualité de l'Air en Île-de-France : La Donnée au Service d'une Ville Plus Saine

« Des données d'aujourd'hui pour une meilleure qualité de l'air demain »

Prévention sanitaire des populations vulnérables, anticipation logistique et hospitalière, sensibilisation citoyenne et industrielle, architecture Cloud automatisée sur 34 stations, pilotage décisionnel (Application Web & Power BI) et Backlog Produit Agile.



Périmètre : Région Île-de-France (34 capteurs · Flux temps réel 30 min · Prévisions J+1) **Année :** 2025 – 2026

Table des Matières

01. Introduction & Contexte : Pourquoi étudier la qualité de l'air est d'utilité publique ? 2
1.1. L'air, une ressource vitale critique au cœur des enjeux sanitaires urbains 2
1.2. Les six grandes plus-values du projet pour la société et les utilisateurs 2
1.3. L'échelle de qualité de l'air et les composants chimiques suivis 3
02. Architecture Globale du Système : De la Collecte aux Utilisateurs 4
2.1. Vue d'ensemble et diagramme de l'architecture déployée 4
2.2. Infrastructure, sécurité des données et accès par profil d'utilisateur 4
03. Collecte Historique et Streaming Temps Réel sur Serveur Distant 5
3.1. Connexion aux données atmosphériques et météorologiques sur 34 stations 5
3.2. Amorçage historique (75 jours) et flux continu toutes les 30 minutes 5
04. Prédictions pour les 24 Prochaines Heures par Intelligence Artificielle 6
4.1. Identifier les facteurs d'accroissement et les schémas récurrents (« patterns ») 6
4.2. Modélisation LightGBM à 24 horizons, résultats de précision et automatisation à 00h45 6
05. Exploitation Décisionnelle : Power BI, Application Web et Mobilité 7
5.1. Architecture de connexion sécurisée vers Power BI (PostgreSQL SSL & Google Sheets) 7
5.2. Valeur ajoutée des tableaux de bord et analyse de la surconcentration routière 7
06. Organisation Agile, Backlog Produit et Synthèse des Livrables 8
6.1. Récapitulatif des six livrables officiels du projet 8
6.2. Backlog Produit mis à jour par Sprints et User Stories 8
07. Conclusion Générale, Perspectives d'Amélioration et Bibliographie 9

01. Introduction & Contexte : Pourquoi étudier la qualité de l'air est d'utilité publique ?

1.1. L'air, une ressource vitale critique au cœur des enjeux sanitaires urbains

Respirer librement est un besoin humain fondamental que l'on accomplit plus de vingt mille fois par jour sans y penser. Pourtant, parmi toutes les ressources naturelles de la Terre, l'air occupe une place singulière et critique : contrairement à l'eau ou à l'alimentation, son absence ou son altération sévère met immédiatement la vie humaine en péril. À l'échelle mondiale, l'Organisation Mondiale de la Santé (OMS, 2021) rappelle que la pollution atmosphérique constitue le premier risque environnemental pour la santé, provoquant près de 4,2 millions de décès prématurés par an. En France, Santé Publique France (2021) évalue cet impact à 40 000 décès annuels, avec une exposition particulièrement marquée en Île-de-France où plus de 12,3 millions d'habitants cohabitent avec un trafic routier et une activité urbaine très denses.

Étudier, surveiller et anticiper la qualité de l'air relève donc d'une véritable mission d'**utilité publique**. C'est dans cet esprit qu'a été conçu notre projet **Smart City** : développer une plateforme complète capable à la fois de parcourir

l'historique de la qualité de l'air sur plusieurs jours en Île-de-France, de suivre la situation en temps réel toutes les trente minutes, et surtout d'afficher la prédiction de l'indice de qualité de l'air pour les **24 prochaines heures**.

1.2. Les six grandes plus-values du projet pour la société et les utilisateurs

Bien au-delà de l'exercice technologique, ce projet a été pensé autour des bénéfices humains, sanitaires et organisationnels qu'il apporte à ses utilisateurs. Six objectifs majeurs structurent notre démarche :

1. **Prévenir d'éventuelles crises sanitaires aiguës :** En cas de dégradation brutale ou imprévue de la qualité de l'air, la plateforme permet d'avertir immédiatement les citoyens afin qu'ils puissent rester à l'abri chez eux et éviter toute exposition dangereuse.
2. **Protéger de manière ciblée les personnes malades et vulnérables :** Les personnes particulièrement sensibles à une baisse de la qualité de l'air (patients asthmatiques, insuffisants respiratoires ou cardiaques, jeunes enfants, personnes âgées) peuvent consulter la prévision avant de sortir et adapter leurs déplacements ou leur traitement préventif.
3. **Sensibiliser les citoyens et responsabiliser les acteurs économiques et industriels :** En rendant visibles et incontestables les niveaux de pollution heure par heure, l'outil permet aux autorités de mener des campagnes de prévention ciblées pour sensibiliser la population et inciter les industriels ainsi que les acteurs du transport à réduire leurs émissions.
4. **Produire des statistiques de référence sur les facteurs de pollution :** Le croisement systématique des polluants et de la météo permet de comprendre scientifiquement quels facteurs provoquent l'accroissement de la pollution (embouteillages, chaleur estivale, absence de vent) ou au contraire sa régression (balayage par le vent, lavage de l'air par la pluie).
5. **Identifier des schémas récurrents (« patterns ») pour l'anticipation matérielle et hospitalière :** Repérer à l'avance le retour des mauvaises périodes donne aux services de santé et aux collectivités la possibilité d'anticiper matériellement les besoins (constitution de stocks de masques, bouteilles d'oxygène, préparation des équipements et des urgences hospitalières face aux pics d'admission pour crises d'asthme ou détresses respiratoires).
6. **Offrir un socle d'analyse pour la recherche scientifique :** La conservation structurée de l'évolution de la qualité de l'air donne aux chercheurs et aux urbanistes la matière nécessaire pour évaluer de nouvelles solutions d'aménagement urbain durable.

1.3. L'échelle de qualité de l'air et les composants chimiques suivis

Afin que chaque citoyen et chaque élu puisse interpréter immédiatement le niveau de risque sans être chimiste, le système s'appuie sur l'indice européen de qualité de l'air (**European AQI**) pour la modélisation régionale, tout en proposant des grilles de lecture visuelles par code couleur universel allant du vert (air sain) au bordeaux/violet (danger sanitaire aigu) :

Niveau de Qualité de l'Air	Échelle Européenne (EAQI)	Échelle Internationale (US AQI)	Couleur	Signification concrète et précautions pour l'utilisateur
Bon	0 – 20	0 – 50	Vert (#00E400)	Qualité de l'air idéale. Aucune restriction : moment privilégié pour le sport en plein air et l'aération des logements et écoles.
Correct / Modéré	20 – 40	51 – 100	Jaune (#FFFF00)	Qualité acceptable. Seules les personnes extrêmement sensibles ou multi-allergiques peuvent ressentir une légère gêne.

Niveau de Qualité de l'Air	Échelle Européenne (EAQI)	Échelle Internationale (US AQI)	Couleur	Signification concrète et précautions pour l'utilisateur
Moyen / Dégradé pour les personnes sensibles	40 – 60	101 – 150	Orange (#FF7E00)	Les personnes asthmatiques, malades ou âgées doivent limiter les efforts prolongés à l'extérieur et garder leur traitement à portée.
Mauvais	60 – 80	151 – 200	Rouge (#FF0000)	Tout le monde peut commencer à ressentir des effets irritants ; les groupes sensibles doivent éviter les sorties aux heures de pointe.
Très mauvais	80 – 100	201 – 300	Violet (#8F3F97)	Alerte sanitaire : déclenchement recommandé des mesures préfectorales (réduction de vitesse, circulation différenciée) et préparation hospitalière.
Extrêmement mauvais / Dangereux	> 100	301 – 500	Bordeaux (#7E0023)	Urgence sanitaire : recommandation générale de rester à l'intérieur et mobilisation des équipements de protection respiratoire.

Pour calculer cet indice et comprendre l'origine exacte de chaque dégradation, la plateforme suit simultanément **sept composants atmosphériques majeurs** : les particules fines **$PM_{2.5}$** (issues des combustions et pénétrant dans le sang ; Pope & Dockery, 2006), les particules **PM_{10}** (liées notamment à l'usure mécanique des freins, pneus et chaussées ; Harrison et al., 2012), le dioxyde d'azote **NO_2** (traceur direct du trafic routier), l'ozone **O_3** (formé l'après-midi sous l'effet du soleil et de la chaleur ; Seinfeld & Pandis, 2016), le dioxyde de soufre **SO_2**, le monoxyde de carbone **CO**, ainsi que le **pollen de bouleau** pour la prévention allergique (D'Amato et al., 2007).

02. Architecture Globale du Système : De la Collecte aux Utilisateurs

2.1. Vue d'ensemble et diagramme de l'architecture déployée

Pour répondre à la devise du projet — *« Des données d'aujourd'hui pour une meilleure qualité de l'air demain »* — nous avons conçu une architecture complète, automatisée de bout en bout et déployée sur un serveur distant léger (sans conteneurisation complexe). Comme l'illustre la **Figure 1** ci-dessous, le système s'articule autour de cinq grandes briques fonctionnelles :

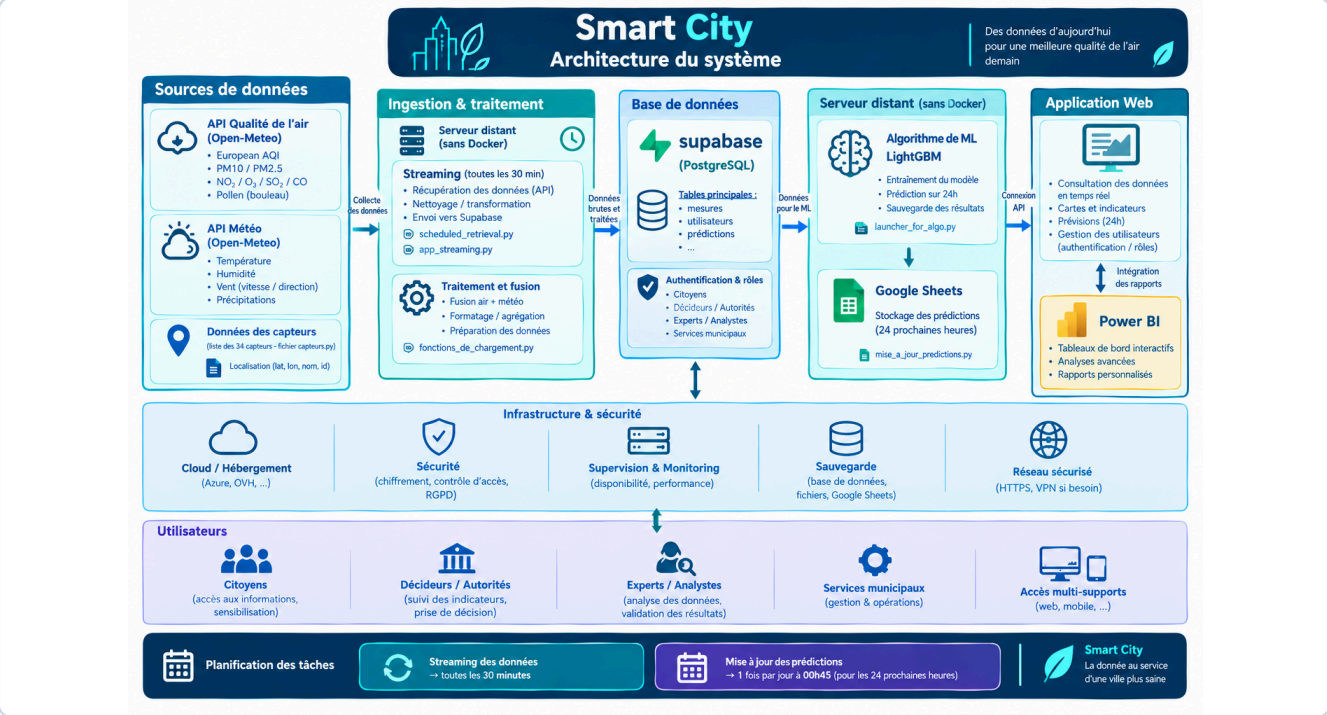


Figure 1 — Diagramme officiel de l'architecture du système Smart City : chaîne de traitement de la donnée depuis les capteurs jusqu'aux quatre profils d'utilisateurs finaux.

1. **1. Sources de données externes :** Interrogation coordonnée de l'API Qualité de l'air (European AQI, PM_{10}, $PM_{2.5}$, NO_2, O_3, SO_2, CO, pollen de bouleau) et de l'API Météo (température, humidité, vent vitesse/direction, précipitations) sur les **34 capteurs d'Île-de-France**.
2. **2. Ingestion et traitement en continu :** Un serveur distant Linux assure le **streaming toutes les 30 minutes** (récupération automatisée, nettoyage, transformation et envoi vers la base) et la **fusion Air + Météo**.
3. **3. Base de données Cloud centralisée (Supabase PostgreSQL) :** Stockage relationnel des mesures, des prévisions et des comptes utilisateurs avec gestion des rôles et des droits d'accès.
4. **4. Serveur distant d'Intelligence Artificielle et passerelle Google Sheets :** Chaque nuit à **00h45**, le serveur exécute l'algorithme de Machine Learning **LightGBM** pour générer les prédictions sur les 24 prochaines heures et les sauvegarde dans une feuille **Google Sheets** dédiée.
5. **5. Application Web et Business Intelligence (Power BI) :** Consultation en temps réel, cartes et indicateurs, prévisions à 24h et intégration directe des rapports analytiques **Power BI**.

2.2. Infrastructure, sécurité des données et accès par profil d'utilisateur

Ce pipeline s'appuie sur un socle transversal d'**Infrastructure et Sécurité** (hébergement Cloud, chiffrement HTTPS/SSL, conformité RGPD, supervision de la disponibilité et sauvegarde triple). Il dessert directement **quatre profils d'utilisateurs** sur ordinateur et mobile : les **Citoyens** (accès à l'information et sensibilisation), les **Décideurs / Autorités**

(suivi des indicateurs et prise de décision), les **Experts / Analystes** (analyse avancée et validation) et les **Services municipaux** (gestion et opérations).

03. Collecte Historique et Streaming Temps Réel sur Serveur Distant

3.1. Connexion aux données atmosphériques et météorologiques sur 34 stations

Le réseau couvre l'ensemble de l'Île-de-France à travers **34 stations géolocalisées** réparties entre **8 stations de trafic routier intense** (Autoroute A1 à Saint-Denis, Boulevard Périphérique Est, Place de l'Opéra, Champs-Élysées, Place Victor Basch, Boulevard de Denain, RN6 à Melun, RN20 à Montlhéry) et **26 stations de fond urbain, périurbain ou rural** (Les Halles, Paris 18e, La Défense, Bobigny, Gennevilliers, Versailles, Cergy-Pontoise, Évry, Forêt de Fontainebleau, Rambouillet, Frémainville, Coulommiers).

3.2. Amorçage historique (75 jours) et flux continu toutes les 30 minutes

Un premier module d'**importation historique** récupère en une seule opération **1 800 heures consécutives (75 jours)** sur les 34 capteurs (plus de 61 000 relevés horaires) pour offrir un recul statistique immédiat. Ensuite, un module de **streaming temps réel** déployé sur un **serveur virtuel privé distant (VPS Linux)** s'exécute automatiquement **toutes les 30 minutes** (via tâche planifiée *cron*), fusionne l'air et la météo sur le fuseau horaire de Paris et alimente la base Supabase sans aucun doublon.

04. Prédictions pour les 24 Prochaines Heures par Intelligence Artificielle

4.1. Identifier les facteurs d'accroissement et les schémas récurrents (« patterns »)

L'analyse statistique menée sur les 34 stations met en évidence trois lois physiques majeures (Figure 2) directement exploitables pour la prévention : le **double pic journalier lié au trafic** (7h–9h et 18h–21h pour le NO_2), l'**accroissement photochimique d'après-midi** par temps chaud et ensoleillé (corrélation température × ozone ***r* = +0,58** avec pic à 15h), et le **rôle dispersif du vent** qui fait régresser les concentrations de NO_2 (***r* = −0,34**) et de $PM_{2.5}$ (***r* = −0,31**).

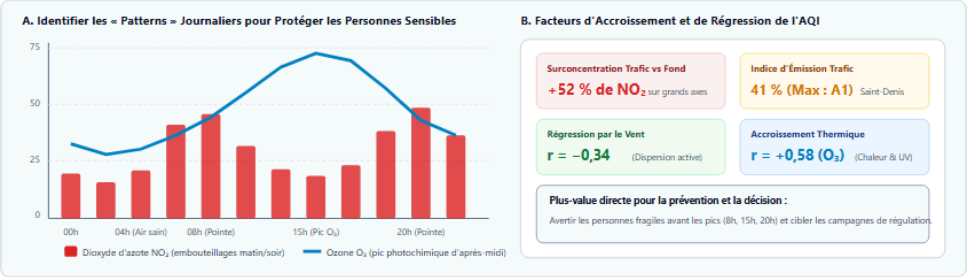


Figure 2 — Identification des schémas journaliers (« patterns ») d'exposition (A) et quantification statistique des facteurs d'accroissement ou de régression de la qualité de l'air en Île-de-France (B).

4.2. Modélisation LightGBM à 24 horizons, résultats de précision et automatisation à 00h45

Pour prédire l'indice AQI sur les 24 prochaines heures sans accumulation d'erreur, le système mobilise **24 modèles LightGBM indépendants** (+1h à +24h) alimentés par **233 variables explicatives** (mémoire des polluants de 1h à 168h, moyennes glissantes, composantes du vent et prévisions météo futures).

Lors de la validation sur 24 heures consécutives en conditions réelles (Figure 3), l'écart absolu moyen (**MAE**) entre l'AQI prédit et l'AQI réel descend à **2,07 points d'AQI** (RMSE = 6,04) sur le capteur de référence, et s'établit à **5,97 points EAQI** sur l'ensemble des 34 stations (près de 80 % de fiabilité). Le calcul s'exécute automatiquement chaque nuit à **00h45** pour publier les prévisions de la journée.

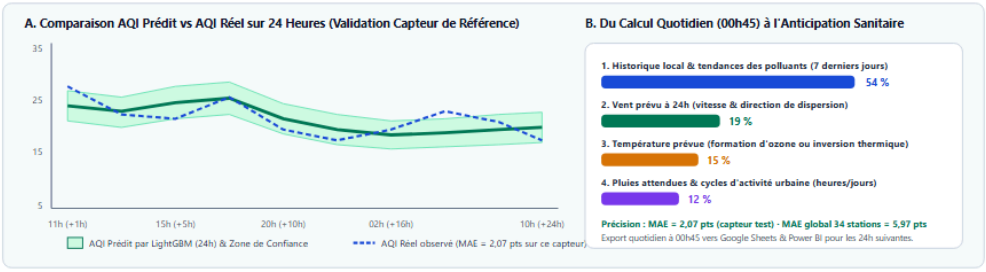


Figure 3 — Confrontation sur 24 heures entre l'AQI prédit et l'AQI réel (MAE = 2,07 points sur le capteur de référence ; MAE = 5,97 points sur les 34 stations) (A) et poids des facteurs explicatifs (B).

05. Exploitation Décisionnelle : Power BI, Application Web et Mobilité

5.1. Architecture de connexion sécurisée vers Power BI (PostgreSQL SSL & Google Sheets)

L'intégration décisionnelle sous **Microsoft Power BI** respecte deux principes de sécurité et d'automatisation :

- **Connexion directe PostgreSQL (Supabase) sécurisée par certificat SSL :** Aucune clé API n'apparaît dans le code applicatif (même chiffrée). La connexion entre Power BI et la base de données est chiffrée et authentifiée par un **certificat SSL** installé sur la machine d'analyse.
- **Passerelle automatisée Google Sheets (Google Workspace) pour les prévisions 24h :** Authentifié par un certificat de service sécurisé, le moteur IA alimente une fois par jour (à 00h45) une feuille Google Sheets dédiée aux 24 prochaines heures, directement connectée à Power BI.

5.2. Valeur ajoutée des tableaux de bord et analyse de la surconcentration routière

En comparant en direct les 8 stations routières aux 26 stations de fond (méthode de Lenschow), l'Application Web et les 6 volets Power BI mettent en évidence une **Surconcentration Trafic vs Fond de +52 %** en dioxyde d'azote (20,5 µg/m³ sur route contre 13,5 µg/m³ en fond) et un **Indice d'Émission Trafic de 41 %** identifiant l'**Autoroute A1 à Saint-Denis** comme axe prioritaire pour les campagnes de régulation.

06. Organisation Agile, Backlog Produit et Synthèse des Livrables

6.1. Récapitulatif des six livrables officiels du projet

L'ensemble des travaux réalisés est structuré autour des six livrables opérationnels suivants, disponibles à la racine du projet :

N°	Livrable officiel	Fichiers et composants livrés	Valeur apportée
1	**Prototype fonctionnel (MVP)**	Application Web Full-Stack (9 onglets) + Backend API & IA + Lanceur 1-clic (`start_smart_city.bat`)	Plateforme opérationnelle temps réel et prédictive à 24h avec gestion des rôles (Admin, Élu, Citoyen).
2	**Backlog produit mis à jour**	`Backlog_Produit_Smart_City.md` & `Backlog_Trello_Jira_Planner.csv`	Backlog Agile complet (7 Epics, 15 User Stories, Story Points, Statuts) importable dans Trello, Jira, MS Planner ou Notion.
3	**Code source structuré (GitHub)**	Dépôt GitHub : `https://github.com/bebeto55/Projet_qualite_air` (branche `main`)	Code modulaire documenté et sécurisé (zéro clé API en clair), synchronisé sur la branche principale GitHub.
4	**Documentation minimale**	`README.md` à la racine du projet	Explication claire de ce que fait l'application, de son architecture et des commandes pour la lancer en 1 clic.
5	**Dashboard BI & Rapport de données**	`Smart_City.pbix` (6 pages Power BI) + `Dashboard_Donnees_Smart_City.pdf` + `Rapport_Projet_Smart_City_Complet.docx` & `.pdf`	Double restitution analytique (outil BI interactif + Dashboard de données illustré en PDF + rapport complet Word et PDF).
6	**Présentation finale & Démo vidéo**	`Air Quality Index (AQI) by Slidesgo.pptx` + `Guide_Soutenance_et_Demo_Video.md`	Support de soutenance courte accompagné du scénario minuté de démonstration vidéo du MVP.

6.2. Backlog Produit mis à jour par Sprints et User Stories

Le développement a été conduit de manière itérative sur quatre sprints complétés par un backlog d'évolutions futures (V2) :

Sprint / Epic	ID	User Story principale	Profil bénéficiaire	Priorité & Points	Statut
Sprint 1 Collecte & Base Cloud	US-01 à US-04	Référencer les 34 stations IdF, importer 1 800h (75j) d'historique Air+Météo, déployer PostgreSQL sur Supabase sans doublon et automatiser le streaming 30 min sur VPS.	Chercheurs & Services municipaux	Haute (P0) 21 pts	Terminé

Sprint / Epic	ID	User Story principale	Profil bénéficiaire	Priorité & Points	Statut
Sprint 2 Prédiction IA 24h	US-05 à US-07	Construire 233 variables, entraîner les 24 modèles LightGBM (MAE = 2,07 pts capteur test / 5,97 pts global) et exporter à 00h45 vers Google Sheets.	Personnes malades, Hôpitaux & Décideurs	Haute (P0) 26 pts	Terminé
Sprint 3 Application Web MVP	US-08 à US-11	Développer les 9 onglets (Temps réel, Carte 34 stations, Mobilité Trafic/Fond +52 %, Prévisions 24h, Alertes email, Rapports PDF, Authentification par rôle).	Citoyens, Élus & Autorités de mobilité	Haute (P0) 24 pts	Terminé
Sprint 4 Power BI & Soutenance	US-12 & US-13	Connecter Power BI à PostgreSQL (certificat SSL) et Google Sheets (6 volets), rédiger le README, le rapport Word/PDF et la présentation finale.	Analystes BI, Élus & Jury	Haute (P0) 13 pts	Terminé
Backlog V2 Perspectives	US-14 & US-15	Allonger la prédiction à 48h/72h, intégrer le comptage routier temps réel et tester d'autres algorithmes de ML/Deep Learning (LSTM, GNN).	Hôpitaux & Chercheurs	Moyenne (P2) 21 pts	Planifié (V2)

07. Conclusion Générale, Perspectives d'Amélioration et Bibliographie

En réalisant de bout en bout cette plateforme — de la collecte historique (75 jours) et temps réel (toutes les 30 minutes sur serveur distant) jusqu'au stockage PostgreSQL sécurisé, à la prédiction des 24 prochaines heures par LightGBM et à la visualisation sous Application Web et Power BI — ce projet démontre comment la donnée et l'intelligence artificielle peuvent servir directement la santé publique, l'anticipation hospitalière et la décision locale. Les perspectives de la version 2 porteront sur l'amélioration continue de la précision, l'extension de l'horizon prédictif au-delà de 24 heures (48h/72h), la convivialité des interfaces et l'expérimentation de nouveaux algorithmes d'apprentissage profond.

[1] OMS (2021). *Lignes directrices mondiales de l'OMS sur la qualité de l'air (PM2.5, PM10, O_3, NO_2, SO_2, CO).* Genève : OMS.

[2] EEA (2023). *Air Quality in Europe 2023 & European Air Quality Index (EAQI) methodology.* Luxembourg : Union européenne.

[3] Santé Publique France (2021). *Pollution de l'air ambiant : estimations de son impact sur la mortalité en France.* Saint-Maurice.

[4] Pope, C. A., & Dockery, D. W. (2006). Health effects of fine particulate air pollution. *J. Air & Waste Manage. Assoc.*, 56(6), 709–742.

[5] Harrison, R. M., et al. (2012). Nonexhaust traffic particles (brake dust, tire wear, resuspension). *Environ. Sci. Technol.*, 46(12), 6523–6529.

[6] Lenschow, P., et al. (2001). Sources of pollutants in urban environments (Trafic vs Background increment). *Atmospheric Environment*, 35, S23–S33.

[7] Ke, G., et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *NeurIPS*, 30 — & **Taieb, S. B., et al. (2012).** Multi-step ahead forecasting strategies. *Expert Systems with Applications*, 39(8), 7067–7083.